

Variational Perspective: From VAEs to DDPMs – II

March 2026

<https://linklab.github.io>

DDPM – Reverse Denoising Process (Learnable Decoder)

Reverse Denoising Process (Learnable Decoder)

Reverse Denoising Process

- The core idea of DDPMs is to reverse the degradation caused by the forward diffusion process
- Generation starts from pure noise $\mathbf{x}_L \sim p_{\text{prior}}$
- The model progressively denoises the noise to recover structure and meaning
- Reverse process is implemented as a Markov chain that produces a data sample step by step

The Fundamental Question

- ? Can we precisely compute, or at least effectively approximate, these reverse transition kernels $p(\mathbf{x}_{i-1} | \mathbf{x}_i)$?, especially when considering the complex distribution of $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$?

$\mathbf{x}_0 \sim p_{\text{data}}$




Figure 2.5: Illustration of DDPM reverse (denoising) process. Starting from noise $\mathbf{x}_L \sim p_{\text{prior}}$, the model sequentially samples $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1} | \mathbf{x}_i)$ for $i = L, \dots, 1$ to obtain a newly generated data $\mathbf{x}$. The oracle transition $p(\mathbf{x}_{i-1} | \mathbf{x}_i)$ is unknown; thus, we aim to approximate it.

Overview: Modeling and Training Objective

⚙️ Intractable Modeling

- Learnable parametric model $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ of reverse transition kernel
- Training objective

$$\mathbb{E}_{p_i(\mathbf{x}_i)} \left[\mathcal{D}_{\text{KL}} \left(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \parallel p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \right) \right]$$

[2.2.2]

- Direct computation of $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ is challenging, so using Bayes' theorem, it is

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i) = p(\mathbf{x}_i \mid \mathbf{x}_{i-1}) \underbrace{\frac{p_{i-1}(\mathbf{x}_{i-1})}{p_i(\mathbf{x}_i)}}_{\text{intractable}}$$

- The following two marginals are expectations over the unknown data distribution p_{data}

$$p_i(\mathbf{x}_i) = \int p_i(\mathbf{x}_i \mid \mathbf{x}_0) p_{data}(\mathbf{x}_0) d\mathbf{x}_0 \qquad p_{i-1}(\mathbf{x}_{i-1}) = \int p_{i-1}(\mathbf{x}_{i-1} \mid \mathbf{x}_0) p_{data}(\mathbf{x}_0) d\mathbf{x}_0$$

- Since p_{data} is unknown, these integrals have no closed-form evaluation

Overview: Modeling and Training Objective

⚙️ Overcoming Intractability with Conditioning

- We **condition the reverse transition on a clean data sample $\mathbf{x}$** .

$$\begin{aligned} p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x}) &= p(\mathbf{x}_i | \mathbf{x}_{i-1}, \mathbf{x}) \frac{p(\mathbf{x}_{i-1} | \mathbf{x})}{p(\mathbf{x}_i | \mathbf{x})} \\ \Downarrow \\ p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x}) &= p(\mathbf{x}_i | \mathbf{x}_{i-1}) \frac{p(\mathbf{x}_{i-1} | \mathbf{x})}{p(\mathbf{x}_i | \mathbf{x})} \end{aligned}$$

- This tractability arises from two key properties of the forward process:
 - Markov property: $p(\mathbf{x}_i | \mathbf{x}_{i-1}, \mathbf{x}) = p(\mathbf{x}_i | \mathbf{x}_{i-1})$
 - $p(\mathbf{x}_i | \mathbf{x})$, $p(\mathbf{x}_{i-1} | \mathbf{x})$: forward process is Gaussian $\rightarrow$ we can get their closed form
 - As a result, $p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x})$ is Gaussian and admits a closed-form expression

Theorem 2.2.1

Equivalence Between Marginal and Conditional KL Minimization

$$\mathbb{E}_{p_i(\mathbf{x}_i)} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1} | \mathbf{x}_i) \| p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i))] \quad [2.2.3]$$

$$= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{p(\mathbf{x}_i | \mathbf{x})} [\mathcal{D}_{\text{KL}}(p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x}) \| p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i))] + C$$

[직관적인 비유]

- 원래 문제 $\rightarrow$ 안개 낀 상태에서 길 찾기 (너무 어려움)
- 바꾼 문제 $\rightarrow$ 지도 들고 길 연습하기 (쉬움)
- 정리가 보장하는 것 $\rightarrow$ 지도를 보고 연습해도, 실제 안개 속에서도 가장 잘 걷는 사람이 된다

Moreover, the minimizer satisfies:

$$\begin{aligned} p^*(\mathbf{x}_{i-1} | \mathbf{x}_i) &= \mathbb{E}_{p(\mathbf{x} | \mathbf{x}_i)} [p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x})] \\ &= p(\mathbf{x}_{i-1} | \mathbf{x}_i), \mathbf{x}_i \sim p_i \end{aligned}$$

**조건을 건 역과정들을
평균내면, 조건 없는 진짜
역과정이 된다**

어려운 KL 문제를, 수학적으로 동등하면서도 계산 가능한 Conditional KL 문제로 바꾸는 것이 DDPM 학습의 핵심

Reverse Conditional Transition Kernel

[DDPG의 핵심 정리]

[Lemma 2.2.2] Reverse Conditional Transition Kernel

$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ is Gaussian with the closed-form expression

$$p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}) = \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i), \sigma^2(i)\mathbf{I})$$

[2.2.4]

where

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2} \mathbf{x} + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i, \quad \sigma^2(i) := \frac{1 - \bar{\alpha}_{i-1}^2}{1 - \bar{\alpha}_i^2} \beta_i^2$$

- 해석 -

: $p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x})$ 는 가우시안 분포이며, 평균과 분산을 명시적인 Closed-form 수식으로 쓸 수 있다

: 현재 noisy 상태 $\mathbf{x}_i$ 와 원본 $\mathbf{x}$ 를 알고 있다면, 바로 이전 상태 $\mathbf{x}_{i-1}$ 는 정확한 가우시안 분포로 표현할 수 있다.

DDPM – Modeling of Reverse Transition Kernel

$$p_{\phi}(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$$

Modeling of Reverse Transition Kernel $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$

⚙️ Reverse transition $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i)$ Modeling and Training

- It is Gaussian, parameterized as $p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) := \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I})$ (2.2.5)
 - $\boldsymbol{\mu}_\phi(\mathbf{x}_i, i): \mathbb{R}^D \rightarrow \mathbb{R}^D$: learnable mean function
 - $\sigma^2(i) > 0$ is fixed
- DDPM loss function on data $\mathbf{x}_0 \sim p_{data} \leftarrow$ It is averaged over time steps i

$$\mathcal{L}_{diffusion}(\mathbf{x}_0; \phi) := \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i | \mathbf{x}_0)} \left[\mathcal{D}_{KL} \left(p(\mathbf{x}_{i-1} \mid \mathbf{x}_i, \mathbf{x}_0) \parallel p_\phi(\mathbf{x}_{i-1} \mid \mathbf{x}_i) \right) \right] \quad (2.2.6)$$

$$= \sum_{i=1}^L \frac{1}{2\sigma^2(i)} \left\| \boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 + C \quad (2.2.7)$$

- C is a constant independent of ϕ
- Final DDPM training objective $\rightarrow$ averaging over the data distribution and omitting the constant C

$$\mathcal{L}_{DDPM}(\phi) := \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \left[\sum_{i=1}^L \frac{1}{2\sigma^2(i)} \left\| \boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right] \quad (2.2.8)$$

DDPM – Practical Choices of Predictions and Loss

Practical Choices of Predictions and Loss

⚙️ ϵ -Prediction (1/2)

- Recall that in the DDPM forward process

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon, \quad \mathbf{x}_0 \sim p_{data}, \quad \epsilon \sim \mathcal{N}(0, I)$$

[2.2.9]

where

$$\bar{\alpha}_i := \prod_{k=1}^i \sqrt{1 - \beta_k^2} = \prod_{k=1}^i \alpha_k.$$

- The reverse mean can be rewritten

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon \Rightarrow \mathbf{x}_0 = \frac{1}{\bar{\alpha}_i} \left(\mathbf{x}_i - \sqrt{1 - \bar{\alpha}_i^2} \epsilon \right) \quad \bar{\alpha}_i = \bar{\alpha}_{i-1} \alpha_i \Rightarrow \frac{\bar{\alpha}_{i-1}}{\bar{\alpha}_i} = \frac{1}{\alpha_i}$$

$$1 - \bar{\alpha}_i^2 = 1 - \bar{\alpha}_{i-1}^2 \alpha_i^2 = (1 - \bar{\alpha}_{i-1}^2) \alpha_i^2 + (1 - \alpha_i^2) = (1 - \bar{\alpha}_{i-1}^2) \alpha_i^2 + \beta_i^2 \Rightarrow \frac{(1 - \bar{\alpha}_{i-1}^2) \alpha_i^2 + \beta_i / \alpha_i}{1 - \bar{\alpha}_i^2} = \frac{1}{\alpha_i}$$

$$\mu(\mathbf{x}_i, \mathbf{x}_0, i) := \frac{\bar{\alpha}_{i-1} \beta_i^2}{1 - \bar{\alpha}_i^2} \mathbf{x}_0 + \frac{(1 - \bar{\alpha}_{i-1}^2) \alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i$$

$$= \frac{\bar{\alpha}_{i-1} \beta_i^2}{1 - \bar{\alpha}_i^2} \frac{1}{\bar{\alpha}_i} \left(\mathbf{x}_i - \sqrt{1 - \bar{\alpha}_i^2} \epsilon \right) + \frac{(1 - \bar{\alpha}_{i-1}^2) \alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i \longrightarrow \mu(\mathbf{x}_i, \mathbf{x}_0, i) := \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right)$$

Practical Choices of Predictions and Loss

⚙️ ϵ -Prediction (2/2)

- a neural network $\epsilon_\phi(\mathbf{x}_i, i)$ can directly predicts the

$$\mu(\mathbf{x}_i, \mathbf{x}_0, i) := \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon \right) \quad \Rightarrow \quad \mu(\mathbf{x}_i, \mathbf{x}_0, i) := \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_\phi(\mathbf{x}_i, i) \right)$$

- Substituting this into the original loss leads to the squared ℓ_2 error

$$\mathcal{L}_{DDPM}(\phi) := \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \left[\sum_{i=1}^L \frac{1}{2\sigma^2(i)} \left\| \mu_\phi(\mathbf{x}_i, i) - \mu(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right] \Rightarrow \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I)} \left[\sum_{i=1}^L \frac{1}{2\sigma^2(i)} \left\| \epsilon_\phi(\mathbf{x}_i, i) - \epsilon \right\|_2^2 \right]$$

- $\epsilon_\phi(\mathbf{x}_i, i)$: forward 과정의 각 단계에서 추가된 무작위 잡음(noise)을 추정하는 '노이즈 예측 모델' 역할
- 이렇게 추정한 잡음을 손상된 샘플에서 제거하면 데이터는 원래의 깨끗한 상태에 더 가까워지며, 이 과정을 단계적으로 반복함으로써 순수한 노이즈로부터 원본 데이터를 재구성할 수 있다.

Practical Choices of Predictions and Loss

⚙️ Simplified Loss with ϵ -Prediction

$$\mathcal{L}_{DDPM}(\phi) := \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \left[\sum_{i=1}^L \frac{1}{2\sigma^2(i)} \|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \right] \Rightarrow \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)} \left[\sum_{i=1}^L \frac{1}{2\sigma^2(i)} \|\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\epsilon}\|_2^2 \right]$$

$$\mathcal{L}_{simple-DDPM}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)} \left[\|\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i) - \boldsymbol{\epsilon}\|_2^2 \right]$$

[2.2.10]

- 즉, ϵ -Prediction 의 Loss는 조건부 최소자승 문제 $\rightarrow$ 단순 MSE를 써도 최적으로는 실제 노이즈의 조건부 기댓값을 학습

$$\boldsymbol{\epsilon}^*(\mathbf{x}_i, i) = \mathbb{E}[\boldsymbol{\epsilon} \mid \mathbf{x}_i], \quad \mathbf{x}_i \sim p_i$$

- Forward 과정에서 $\mathbf{x}_i$ 의 생성과정

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \boldsymbol{\epsilon}, \quad \mathbf{x}_0 \sim p_{data}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$$

- 즉, $\boldsymbol{\epsilon}_\phi(\mathbf{x}_i, i)$ 는 i 번째 과정에서 섞인 노이즈를 추정함
- 원래 DDPM Loss: 한 단계 전으로 되돌아가는 평균($\boldsymbol{\mu}$)을 잘 맞추자
- 단순 DDPM Loss: 한 단계 전으로 되돌아가기 위하여 섞였던 노이즈($\boldsymbol{\epsilon}$)를 잘 맞추자
- 이 때문에 ϵ -Prediction 의 Loss는 원래 DDPM loss와 이론상 동일한 최적해를 갖는다.

Practical Choices of Predictions and Loss

⚙️ x-Prediction: Another Equivalent Parametrization

- a neural network $\mathbf{x}_\phi(\mathbf{x}_i, i)$ is trained to predict a clean (denoised) sample from a given noisy input $\mathbf{x}_i \sim p_i(\mathbf{x}_i)$ at noise level i

$$\mathbf{x} = \mathbf{x}_\phi(\mathbf{x}_i, i)$$

- In the reverse mean expression, replacing the clean sample $\mathbf{x}$ with $\mathbf{x}_\phi(\mathbf{x}_i, i)$ leads

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2} \mathbf{x} + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i \longrightarrow \boldsymbol{\mu}(\mathbf{x}_i, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1 - \bar{\alpha}_i^2} \mathbf{x}_\phi(\mathbf{x}_i, i) + \frac{(1 - \bar{\alpha}_{i-1}^2)\alpha_i}{1 - \bar{\alpha}_i^2} \mathbf{x}_i$$

- The reverse mean can be rewritten

$$\|\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i)\|_2^2 \propto \|\mathbf{x}_\phi(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2, \quad \mathbf{x}_0 \sim p_{data},$$

- Another equivalent loss $\mathcal{L}_{simple-DDPM-2}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x}_0 \sim p_{data}} \mathbb{E}_{\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)} \left[\omega_i \|\mathbf{x}_\phi(\mathbf{x}_i, i) - \mathbf{x}_0\|_2^2 \right]$

- The optimal solution

$$\mathbf{x}^*(\mathbf{x}_i, i) = \mathbb{E}[\mathbf{x}_0 \mid \mathbf{x}_i], \quad \mathbf{x}_i \sim p_i$$

[2.2.11]

Practical Choices of Predictions and Loss

⚙️ The Combination

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_\phi(\mathbf{x}_i, i) + \sqrt{1 - \bar{\alpha}_i^2} \epsilon_\phi(\mathbf{x}_i, i) \quad [2.2.12]$$

x-prediction과 ϵ -prediction은 서로 맞춰서 합치면 반드시 같은 x_i 를 만들어야 한다.

즉,

- x_ϕ 를 정확히 알면 $\rightarrow \epsilon_\phi$ 는 자동으로 결정되고
- ϵ_ϕ 를 정확히 알면 $\rightarrow x_\phi$ 도 자동으로 결정됩니다.

⚙️ ϵ -Prediction VS. x-Prediction

ϵ -prediction

타겟:

$$\epsilon \sim \mathcal{N}(0, I)$$

- 모든 timestep에서 분산 = 1
- loss 스케일이 시간에 따라 변하지 않음
- $\Rightarrow$ weighting을 제거해도 학습 안정

그래서 최종적으로

$$\mathbb{E} \|\epsilon_\phi - \epsilon\|^2$$

만 남김

x-prediction

x-Prediction는 왜 ω_i 가 필요한가?

타겟:

$$x_0 \sim p_{\text{data}}$$

하지만 모델이 보는 입력은:

$$x_i = \bar{\alpha}_i x_0 + \sqrt{1 - \bar{\alpha}_i^2} \epsilon$$

즉,

- 큰 i (많이 노이즈가 섞인 단계):
 - x_i 거의 노이즈
 - x_0 예측 매우 어려움
- 작은 i :
 - 거의 깨끗한 데이터
 - 예측 쉬움

$\rightarrow$ timestep마다 예측 난이도와 오차 스케일이 다름

DDPM – DDPM's ELBO

DDPM's ELBO

⚙️ The marginal generative model (**likelihood**) for data

$$p_\phi(\mathbf{x}_0) := \int p_\phi(\mathbf{x}_0, \mathbf{x}_{1:L}) d\mathbf{x}_{1:L} = \int p_\phi(\mathbf{x}_0 | \mathbf{x}_1) p_\phi(\mathbf{x}_1 | \mathbf{x}_2) \cdots p_\phi(\mathbf{x}_{L-1} | \mathbf{x}_L) p_{prior}(\mathbf{x}_L) d\mathbf{x}_{1:L}$$

⚙️ DDPM's ELBO (Theorem 2.2.3)

$$-\log p_\phi(\mathbf{x}_0) \leq -\mathcal{L}_{ELBO}(\mathbf{x}_0; \phi)$$

$$:= \mathcal{L}_{Prior}(\mathbf{x}_0) + \mathcal{L}_{recon}(\mathbf{x}_0; \phi) + \mathcal{L}_{diffusion}(\mathbf{x}_0; \phi) \#$$

[2.2.13]

– Here, each component of losses are defined as:

$$\mathcal{L}_{Prior}(\mathbf{x}_0) := \mathcal{D}_{KL}(p(\mathbf{x}_L | \mathbf{x}_0) \| p_{prior}(\mathbf{x}_L))$$

$p(\cdot | \mathbf{x}_0) \approx p_{prior}(\cdot)$ 이 되도록 노이즈 스케줄 $\{\beta_i\}$ 를 잘 선택하면 우리가 설정한 prior도 가우시안이 됨 → 따라서, 이 Loss는 무시

$$\mathcal{L}_{recon}(\mathbf{x}_0; \phi) := \mathbb{E}_{p(\mathbf{x}_1 | \mathbf{x}_0)} [-\log p_\phi(\mathbf{x}_0 | \mathbf{x}_1)]$$

$\mathbf{x}_1$ 에서 $\mathbf{x}_0$ 으로 한번에 복원하는 Loss
→ Monte Carlo 샘플링으로 근사

$$\mathcal{L}_{diffusion}(\mathbf{x}_0; \phi) := \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i | \mathbf{x}_0)} [\mathcal{D}_{KL}(p(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i))]$$

matches the reverse conditionals
 $p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i, \mathbf{x}_0)$ (진짜 역분포) to
 $p(\mathbf{x}_{i-1} | \mathbf{x}_i)$ (모델이 만드는 역분포)

DDPM's ELBO

Alternative Interpretation of DDPM's ELBO (Data Processing Inequality의 관점)

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}(\mathbf{x}_0) \| p_{\phi}(\mathbf{x}_0)) \leq \mathcal{D}_{\text{KL}}(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \| p_{\phi}(\mathbf{x}_0, \mathbf{x}_{1:L}))$$

오른쪽 분포에는 $\mathbf{x}_0$ 뿐 아니라 모든 중간 노이즈 단계 $\mathbf{x}_{1:L}$ 가 포함됨

→ 즉, 더 많은 정보를 포함

→ 전체 경로를 맞추는 것은 최종 결과만 맞추는 것보다 항상 더 어렵다

→ KL이 더 크거나 같다.

$$\min_{\phi} \mathcal{D}_{\text{KL}}(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \| p_{\phi}(\mathbf{x}_0, \mathbf{x}_{1:L})) \longrightarrow \min_{\phi} \mathcal{D}_{\text{KL}}(p(\mathbf{x}_0, \mathbf{x}_{1:L}) \| p_{\phi}(\mathbf{x}_0, \mathbf{x}_{1:L}))$$

모든 step에서 진짜 reverse transition과 모델
reverse transition을 맞추면

→

DPI(Data Processing Inequality)에 의해 자동으로
 $p_{\phi}(\mathbf{x}_0)$ 는 $p_{\text{data}}(\mathbf{x}_0)$ 와 비슷해짐

DDPM's ELBO

⚙️ DDPM's ELBO 의 Diffusion 모델의 변분적 관점

- HVAE 관점에서의 DDPM 구조

- DDPM 모델의 변분적 해석은 HVAE(Hierarchical VAE) 구조와 동일한 틀로 이해할 수 있다.
- 잠재변수 $x_{1:L}$ 는 원본 데이터와 동일한 차원을 가지는 계층적 latent들이다.

- 인코더의 역할과 차이점

- DDPM 에서는 학습되는 인코더가 없고, 고정된 forward noising 과정이 인코더 역할을 한다.

- 학습 목표와 목적 함수 분해

- 학습 목표는 HVAE와 마찬가지로 ELBO를 최대화하는 것이다.
- 계층별 KL 항을 직접 두는 대신, 목표 함수는 단계별 디노이징 문제들의 합으로 분해된다.

- Coarse-to-Fine 디노이징의 효과

- 이 디노이징 문제들은 큰 노이즈 → 작은 노이즈 (coarse → fine) 순서로 잘 조건화되어 있다.
- 그 결과 학습이 안정적이고, 높은 샘플 품질과 자연스러운 계층적 복원 구조를 얻을 수 있다.

DDPM – Sampling

Sampling

⚙️ Sampling Method




Figure 2.5: Illustration of DDPM reverse (denoising) process. Starting from noise $\mathbf{x}_L \sim p_{\text{prior}}$, the model sequentially samples $\mathbf{x}_{i-1} \sim p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ for $i = L, \dots, 1$ to obtain a newly generated data $\mathbf{x}$. The oracle transition $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ is unknown; thus, we aim to approximate it.

- After training the ϵ -Prediction model, $\epsilon_\phi(\mathbf{x}_i, i)$, sampling is performed sequentially using the parametrized transition $p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i)$ instead
 - Starting from a random seed $\mathbf{x}_L \sim p_{\text{prior}} = \mathcal{N}(\mathbf{0}, \mathbf{I})$
 - we recursively sample from $p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i)$ following the update rule below for $i = L, L - 1, \dots, 1$

$$\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_\phi(\mathbf{x}_i, i) \right)}_{\mu_\phi(\mathbf{x}_i, i)} + \sigma(i) \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad [2.2.14]$$

- This "denoising" process continues until $\mathbf{x}_0$ is obtained as the final clean generated sample

Sampling

⚙️ Another Interpretation of DDPM's Sampling

[2.2.12]

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_\phi(\mathbf{x}_i, i) + \sqrt{1 - \bar{\alpha}_i^2} \epsilon_\phi(\mathbf{x}_i, i) \longrightarrow \mathbf{x}_\phi(\mathbf{x}_i, i) = \frac{\mathbf{x}_i - \sqrt{1 - \bar{\alpha}_i^2} \epsilon_\phi(\mathbf{x}_i, i)}{\bar{\alpha}_i}$$

- 노이즈 $\epsilon_\phi(\mathbf{x}_i, i)$ 을 추정할 수 있다면, 그로부터 원본 추정치 $\hat{\mathbf{x}}_0$ 를 계산할 수 있음

$$\mathbf{x}_{i-1} \leftarrow \underbrace{\frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \epsilon_\phi(\mathbf{x}_i, i) \right)}_{\mu_\phi(\mathbf{x}_i, i)} + \sigma(i) \epsilon_i \longrightarrow \mu_\phi(\mathbf{x}_i, i) = (\dots) \cdot \mathbf{x}_i + (\dots) \cdot \hat{\mathbf{x}}_0$$

$\mathbf{x}_{i-1} \leftarrow$ interpolation between $\mathbf{x}_i$ and clean prediction $\hat{\mathbf{x}}_0$ $+ \sigma(i) \epsilon_i$

- $\mathbf{x}_{i-1}$ 를 만드는 방법은 항상 $\hat{\mathbf{x}}_0$ 을 "목표 중심점"으로 삼아 Gaussian Noise를 추가하여 샘플링함


Sampling

⚙️ Another Interpretation of DDPM's Sampling

- DDPM 샘플링은 **반복적 디노이징(iterative denoising)** 으로 해석할 수 있으며, 매 스텝마다 다음 두 과정을 번갈아 수행한다.

1) 현재 노이즈 상태 $\mathbf{x}_i$ 로부터 깨끗한 데이터 추정치 $\hat{\mathbf{x}}_0 = \mathbf{x}_\phi(\mathbf{x}_i, i)$ 를 계산한다.

2) 이 $\hat{\mathbf{x}}_0$ 을 기준으로 업데이트 규칙을 적용해 더 적은 노이즈의 상태 $\mathbf{x}_i$ 을 확률적으로 샘플링한다.



Sampling


⚙️ Another Interpretation of DDPM's Sampling

– Optimal Denoiser와 Blurry 예측의 원인

- 모델 $x_\phi(x_i, i)$ 은 MSE 기준에서 조건부 기댓값 $\mathbb{E}[x_0 | x_i]$ 을 예측하는 Optimal Denoiser로 학습됨
- 조건부 기댓값은 여러 가능한 깨끗한 샘플의 평균이므로, 본질적으로 선명하지 않은(blurry) 예측을 만들

– 고노이즈 단계에서의 구조 복원 한계

- 이 현상은 특히 노이즈가 큰 초기 단계에서 심각하다.
- 즉, 초기에는 심하게 손상된 입력으로부터 세부 구조를 복원하기 어렵다.




Sampling

⚙️ Another Interpretation of DDPM's Sampling

– Coarse-to-Fine Diffusion 샘플링 전략

- 이러한 한계 때문에 diffusion 샘플링은 고노이즈 → 저노이즈 방향으로 진행된다.
- 초기 단계는 데이터의 전역적 구조 (coarse structure)를 결정한다.
- 이후 단계들은 점차 세부 디테일(fine detail)을 보완한다.
- 결과적으로 노이즈가 제거될수록 샘플은 점점 더 현실적인 형태로 정제된다.



Sampling

⚙️ Slow Sampling Speed of DDPM

- 근본적인 샘플링 병목

- DDPM 샘플링이 느린 근본 이유는 Reverse 과정이 단계별 순차적(sequential) 이기 때문

- Reverse 분포 모델링의 한계

- 이론적으로는 충분히 표현력 있는 $p_\phi(\mathbf{x}_{i-1} | \mathbf{x}_i)$ 가 진짜 reverse 분포 $p(\mathbf{x}_{i-1} | \mathbf{x}_i)$ 를 맞출 수 있음
- 그러나, 보통 단일 Gaussian 분포를 기반으로 위 과정을 모델링하기 때문에 표현력이 제한됨

- 노이즈 스케일 β_i 와 근사 정확도

- forward 노이즈 스케일 β_i 가 작으면 진짜 reverse 분포가 거의 Gaussian 이라서 단일 Gaussian 근사가 잘 맞는다.
- 반대로 β_i 가 크면 reverse 분포가 다봉성(multimodality) 또는 강한 비가우시안성을 띠어 단일 Gaussian이 포착하기 어렵다.

Sampling

⚙️ Slow Sampling Speed of DDPM

- DDPM에 많은 스텝이 필요한 이유
 - 정확도를 유지하려면 DDPM은 큰 β_i 를 쓰기보다 작은 β_i 를 많이 쪼개 여러 단계로 진행해야 함
 - 그 결과 샘플링은 길이 L 의 체인에서 매 단계마다 신경망 $\epsilon_\phi(\mathbf{x}_i, i)$ 을 평가
- 계산 복잡도와 속도 문제
 - 샘플리에는 총 $\mathcal{O}(L)$ 번의 순차적인 네트워크 평가가 필요
 - 이 순차 구조는 병렬화(parallelization)를 막아 생성 속도를 크게 저하시킴
- 이후 전개 방향
 - 이후 장에서는 이 병목을 미분방정식(continuous-time) 관점으로 재해석
 - 따라서, 더 빠른 연속시간 수치해법 기반 가속 전략으로 이어짐