

Score-Based Perspective: From EBMs to NCSN – I

March 2026

<https://linklab.github.io>

Energy-Based Model 101

📌 Introduction of Energy-Based Model (EBM)

- Diffusion 모델은 VAE 관점 외에도 Energy-Based Model (EBM) 로 해석 가능
 - EBM은 데이터를 에너지 지형으로 표현 (데이터 영역: 낮은 에너지, 비데이터 영역: 높은 에너지)
 - 데이터 분포 확률은 대략적으로 다음과 같이 정의됨 $p(x) \propto \exp(-E(x))$
- Score와 샘플링
 - 샘플링은 Langevin dynamics 사용
 - 에너지 지형의 기울기(gradient)를 따라 높은 확률 영역으로 이동
 - 이 기울기를 Score ($\nabla_x \log p(x)$)라고 부름 (Score: 확률이 증가하는 방향을 가리키는 벡터장)
- 핵심 아이디어
 - Score만 알면 데이터 생성 가능
 - Diffusion은 노이즈가 섞인 분포들의 score를 학습

Energy-Based Model 101

🔧 Introduction of Energy-Based Model (EBM)

- 노이즈 분포의 Score 학습과 Progressive Denoising 생성
 - 깨끗한 데이터 분포만 직접 다루는 대신, 가우시안 노이즈가 섞인 여러 단계의 분포들(노이즈 레벨 별 분포)을 순서대로 고려한다.
 - 이런 분포들은 더 매끈해서 score(확률의 기울기)를 근사하기가 상대적으로 쉽다.
 - 각 단계의 score를 학습하면, 노이즈 레벨마다 벡터장(vector field)이 하나씩 생긴다.
 - 이 벡터장들이 노이즈 샘플을 단계적으로 데이터 쪽으로 안내하여, 생성 과정이 점진적 디노이징 (progressive denoising) 으로 바뀐다.

Energy-Based Models

Energy-Based Models

⚙️ Definition: Energy-Based Models

- Let $\mathbf{x} \in \mathbb{R}^D$ denote a data point
- EBMs define a probability density via an energy function $E_\phi(\mathbf{x})$, parameterized by ϕ , which assigns lower energy to more likely configurations
- The resulting distribution is given by

$$p_\phi(\mathbf{x}) := \frac{\exp(-E_\phi(\mathbf{x}))}{Z_\phi}, \quad Z_\phi := \int_{\mathbb{R}^D} \exp(-E_\phi(\mathbf{x})) d\mathbf{x}$$

where Z_ϕ is called the partition function ensuring normalization:

$$\int_{\mathbb{R}^D} p_\phi(\mathbf{x}) d\mathbf{x} = 1$$

Energy-Based Models

Definition: Energy-Based Models

Energy-Based Model(EBM)에서는
에너지가 낮을수록 확률이 높다고 생각합니다.

이를 직관적으로 보면:

- 전체 공간을 지형(landscape) 이라고 생각하고
- 각 위치의 높이가 에너지
- 그 위에 공을 하나 굴린다고 상상하면 됩니다.

그러면:

- 골짜기(낮은 에너지) 로 공이 모이고
- 산봉우리(높은 에너지) 에는 공이 거의 가지 않습니다.

즉,

에너지가 낮은 위치 = 데이터가 자주 나타나는 위치

입니다.




Figure 3.1: Illustration of EBM training. The model lowers density (raises energy) at “bad” data points (red arrows), and raises density (lowers energy) at “good” data points (green arrows).

- **전역적 균형(Trade-off)**
 - 어떤 지역의 에너지를 낮춰서 확률을 키우면 전체 합이 1을 넘어가려 함
 - 그러면 자동으로 다른 지역들의 확률이 줄어듦
- EBM은 "아무 데나 다 높은 확률"을 줄 수 없고 진짜 데이터가 있는 영역만 강조하도록 강제함
- EBM은 데이터 분포를 전역적으로 균형 있게 모델링한다!

Energy-Based Models

⚙️ Challenges of Maximum Likelihood Training in EBMs.

- In principle, EBMs can be trained by maximum likelihood

$$\begin{aligned}\mathcal{L}_{\text{MLE}}(\phi) &= \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [p_{\phi}(\mathbf{x})] = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\log \frac{\exp(-E_{\phi}(\mathbf{x}))}{Z_{\phi}} \right] & Z_{\phi} &:= \int_{\mathbb{R}^D} \exp(-E_{\phi}(\mathbf{x})) d\mathbf{x} \\ &= -\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [E_{\phi}(\mathbf{x})] - \log Z_{\phi} & & \\ &= \underbrace{-\mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [E_{\phi}(\mathbf{x})]}_{\text{lowers energy of data}} - \underbrace{\log \int \exp(-E_{\phi}(\mathbf{x})) d\mathbf{x}}_{\text{global regularization}}\end{aligned}$$

- 위 식에서의 문제: $\log Z_{\phi} = \log \int \exp(-E_{\phi}(\mathbf{x})) d\mathbf{x}$ 계산 문제
 - 실제 데이터는 보통 고차원(high-dimensional)
 - 모든 가능한 입력 공간에 대한 적분 → 현실적으로 계산이 불가능(intractable)
- 두가지 우회 전략
 - Contrastive Divergence: $\log Z_{\phi}$ 항을 정확히 계산하지 않고 근사)
 - Score Matching: $\log Z_{\phi}$ 항 자체를 계산하지 않도록 설계 → Score만 학습

diffusion 모델의 전략

Motivation: What Is the Score?

Score Function

- For a density $p(\mathbf{x})$ on $\mathbb{R}^D$, the score function is the gradient of the log-density

$$\mathbf{s}(\mathbf{x}) := \nabla_{\mathbf{x}} \log p(\mathbf{x}), \quad \mathbf{s}: \mathbb{R}^D \rightarrow \mathbb{R}^D$$

- Score Function $\mathbf{s}(\mathbf{x})$ 은 "확률이 높은 곳을 가리키는 화살표" 역할 수행

핵심 요약

개념	설명
벡터장	공간의 모든 점에 화살표가 정의됨
화살표 방향	확률이 더 높아지는 쪽
역할	데이터가 있을 법한 곳으로 안내하는 "지도"

비유

산에서 ***정상으로 가는 방향 표지판***과 같습니다.

- 어느 위치에서 있든, 표지판이 더 높은 곳을 가리킴
- 표지판을 따라가면 결국 정상(고확률 영역)에 도달




Figure 3.2: Illustration of score vector fields. Score vector fields $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ indicate directions of increasing density.

Motivation: What Is the Score?

⚙️ Why Model Scores Instead of Densities?

- 1. 정규화 상수로부터의 자유

문제 상황

Energy-Based Model(EBM)에서 확률분포는 다음과 같이 정의됩니다:

$$p(\mathbf{x}) = \frac{\tilde{p}(\mathbf{x})}{Z}, \quad Z = \int \tilde{p}(\mathbf{x}) d\mathbf{x}$$

여기서:

- $\tilde{p}(\mathbf{x}) = \exp(-E_\phi(\mathbf{x}))$: 비정규화 밀도 (계산 가능)
- Z : 정규화 상수 (계산 불가능 — 고차원 적분)

Score의 해결책

Score function을 계산하면:

$$\nabla_x \log p(\mathbf{x}) = \nabla_x \log \tilde{p}(\mathbf{x}) - \underbrace{\nabla_x \log Z}_{=0} = \nabla_x \log \tilde{p}(\mathbf{x})$$

Z 는 $\mathbf{x}$ 에 대해 상수이므로 미분하면 사라집니다.

- 2. 완전한 표현력

핵심 주장

Score function은 원래 분포를 완전히 복원할 수 있습니다.

복원 공식

$$\log p(\mathbf{x}) = \log p(\mathbf{x}_0) + \int_0^1 \mathbf{s}(\mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0))^\top (\mathbf{x} - \mathbf{x}_0) dt$$

여기서:

- $\mathbf{x}_0$: 기준점 (reference point)
- $\mathbf{s}(\cdot) = \nabla_x \log p(\cdot)$: score function

의미

관점	설명
수학적	Score를 선적분하면 log-density 복원 가능
실용적	Score만 알면 분포의 모든 정보를 담고 있음
장점	Score 모델링이 density 모델링만큼 표현력 있으면서, 더 다루기 쉬움

Motivation: What Is the Score?

⚙️ Why Model Scores Instead of Densities?

복원 공식

$$\log p(\mathbf{x}) = \log p(\mathbf{x}_0) + \int_0^1 \mathbf{s}(\mathbf{x}_0 + t(\mathbf{x} - \mathbf{x}_0))^\top (\mathbf{x} - \mathbf{x}_0) dt$$

Step 1: 기준점 선택

$x_0 = 0$ 을 기준점으로 선택합니다.

정규화 조건에서:

$$\log p(x_0) = \log p(0) = \log \frac{1}{\sqrt{2\pi}} = -\frac{1}{2} \log(2\pi)$$

Step 2: 적분 경로 설정

$x_0 = 0$ 에서 임의의 점 x 까지의 경로:

$$\gamma(t) = x_0 + t(x - x_0) = 0 + t(x - 0) = tx, \quad t \in [0, 1]$$

t	위치 $\gamma(t)$
0	0 (시작점)
0.5	$x/2$ (중간)
1	x (도착점)

Step 3: 적분 계산

1D에서 복원 공식:

$$\log p(x) = \log p(0) + \int_0^1 s(tx) \cdot x dt$$

Score 대입:

$$\int_0^1 s(tx) \cdot x dt = \int_0^1 (-tx) \cdot x dt = \int_0^1 -tx^2 dt$$

적분 실행:

$$= -x^2 \int_0^1 t dt = -x^2 \cdot \left[\frac{t^2}{2} \right]_0^1 = -x^2 \cdot \frac{1}{2} = -\frac{x^2}{2}$$

Step 4: 최종 결과

$$\log p(x) = \underbrace{-\frac{1}{2} \log(2\pi)}_{\log p(0)} + \underbrace{\left(-\frac{x^2}{2}\right)}_{\text{적분 결과}} = -\frac{1}{2} \log(2\pi) - \frac{x^2}{2}$$

이것은 정확히:

$$\log p(x) = \log \left(\frac{1}{\sqrt{2\pi}} e^{-x^2/2} \right) \quad \checkmark$$

예시: 1D 표준정규분포

설정

실제 분포가 $p(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$ 라고 합시다.

우리가 아는 것: Score function $s(x) = -x$

우리가 복원할 것: $\log p(x)$

Training EBMs via Score Matching

Score Matching

- leverages the fact that scores depend only on the energy function
- it trains EBMs by aligning the model score with the (unknown) data score

$$\mathcal{L}_{\text{SM}}(\phi) := \frac{1}{2} \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left\| \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x}) \right\|_2^2$$



$$\mathcal{L}_{\text{SM}}(\phi) := \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \left[\text{Tr} \left(\nabla_{\mathbf{x}}^2 E_{\phi}(\mathbf{x}) \right) + \frac{1}{2} \left\| \nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}) \right\|_2^2 \right] + C$$

integration by parts

the data score is removed

where

- $\nabla_{\mathbf{x}}^2 E_{\phi}(\mathbf{x})$ is the Hessian of E_{ϕ}
- C is a constant independent of ϕ

장점

- 정규화 상수 Z 계산 불필요
- 학습 중 모델에서 샘플링할 필요 없음

단점

- 2차 미분(Hessian) 계산 필요 → 고차원에서 계산 비용이 매우 큼



이 한계를 극복하는 방법들(denoising score matching 등)은 이후에 다뤄집니다.

[Score Matching의 장단점 요약]

Langevin Sampling with Score Functions

⚙️ Langevin Dynamics

- Sampling from EBMs is performed using Langevin dynamics based on the energy function $E_\phi(\mathbf{x})$
- Particle Motion by ODE (Ordinary Differential Equation)
 - According to Newtonian dynamics, the motion of a particle under the force field derived from $E_\phi(\mathbf{x})$ is described by the ODE
$$\frac{d\mathbf{x}(t)}{dt} = -\nabla_{\mathbf{x}} E_\phi(\mathbf{x}(t))$$
 - It deterministically drives the particle downhill toward a local minimum of the energy function



Langevin Sampling with Score Functions

⚙️ Langevin Dynamics

시간이 지남에 따라 입자는 에너지가 낮은 곳으로 이동하면서도, 동시에 랜덤하게 흔들리도록 모델링

- Solving of Current ODE Drawback → **SDE (Stochastic Differential Equation)**
 - It can be trapped in local minima, preventing exploration of the full data distribution
 - To overcome this limitation, Langevin dynamics introduces stochastic differential equation (SDE)

$$\frac{dx(t)}{dt} = -\nabla_x E_\phi(\mathbf{x}(t)) \Rightarrow d\mathbf{x}(t) = -\nabla_x E_\phi(\mathbf{x}(t))dt \Rightarrow d\mathbf{x}(t) = -\nabla_x E_\phi(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t) \text{ Injected noise}$$

where $\mathbf{w}(t)$ is a standard Brownian motion (a. k. a. Wiener process)

- Brownian motion (Wiener Process)

Wiener Process의 정의

Wiener process $\mathbf{w}(t)$ 는 다음 네 가지 성질을 만족하는 확률과정입니다:

성질	수학적 표현	의미
초기값	$\mathbf{w}(0) = \mathbf{0}$	원점에서 시작
독립 증분	$\mathbf{w}(t_2) - \mathbf{w}(t_1)$ 과 $\mathbf{w}(t_4) - \mathbf{w}(t_3)$ 이 독립 (구간이 안 겹치면)	과거가 미래에 영향 없음
정규 증분	$\mathbf{w}(t) - \mathbf{w}(s) \sim \mathcal{N}(\mathbf{0}, (t-s)\mathbf{I})$	증분이 정규분포
연속 경로	$\mathbf{w}(t)$ 가 t 에 대해 연속	점프 없이 매끄럽게 이어짐

증분의 분포: $\mathbf{w}(t + \eta) - \mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \eta\mathbf{I})$

의미 분해

d 차원에서 이 증분 $\Delta\mathbf{w} = \mathbf{w}(t + \eta) - \mathbf{w}(t)$ 는:

$$\Delta\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \eta\mathbf{I}_d)$$

이것을 풀어쓰면:

기호	의미
$\mathbf{0}$	평균이 영벡터 (drift 없음)
$\eta\mathbf{I}_d$	공분산 행렬이 η 배의 단위행렬

$$\Delta\mathbf{w} = \mathbf{w}(t + \eta) - \mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \eta\mathbf{I}) = \sqrt{\eta} \cdot \mathcal{N}(\mathbf{0}, \mathbf{I}) = \sqrt{\eta} \cdot \epsilon \text{ with } \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

Langevin Sampling with Score Functions

⚙️ Langevin Dynamics

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

시간이 지남에 따라 입자는 에너지가 낮은 곳으로 이동하면서도, 동시에 랜덤하게 흔들리도록 모델링

우리가 원하는 것:

$$p_{\phi}(\mathbf{x}) := \frac{1}{Z(\phi)} \exp(-E_{\phi}(\mathbf{x}))$$

즉, Langevin Dynamics 을
아주 오랫동안 수행하면 $\mathbf{x}(t)$ 가
 $p_{\phi}(\mathbf{x})$ 를 따라 샘플링 되기를 원함.

With the factor $\sqrt{2}$, the Langevin Dynamics leave p_{ϕ}
unchanged in time. Namely, p_{ϕ} is stationary:
if $\mathbf{x}(0) \sim p_{\phi}$ then $\mathbf{x}(t) \sim p_{\phi}$ for all $t \geq 0$.

Fokker-Planck Equation

확률밀도 $\rho(\mathbf{x}, t)$ 일 때

$$\frac{\partial \rho(\mathbf{x}, t)}{\partial t} = -\nabla_{\mathbf{x}} \cdot (\rho(\mathbf{x}, t) \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x})) + \frac{\sigma^2}{2} \Delta_{\mathbf{x}} \rho(\mathbf{x}, t)$$

여기서

- $\rho(\mathbf{x}, t)$: 시간 t 에서의 확률밀도
- $\frac{\partial \rho(\mathbf{x}, t)}{\partial t}$: 시간 t 에 대한 편미분
- $\nabla_{\mathbf{x}}$: 상태 변수 $\mathbf{x}$ 에 대한 Gradient
- $\Delta_{\mathbf{x}} = \nabla_{\mathbf{x}} \cdot \nabla_{\mathbf{x}}$: 상태 변수 $\mathbf{x}$ 에 대한 Laplacian

Langevin Sampling

⚙️ Langevin Dynamics

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

Fokker-Planck Equation

$$\frac{\partial \rho(\mathbf{x}, t)}{\partial t} = -\nabla_{\mathbf{x}} \cdot (\rho(\mathbf{x}, t) \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x})) + \frac{\sigma^2}{2} \Delta_{\mathbf{x}} \rho(\mathbf{x}, t)$$

Stationary Distribution과 $\sigma = \sqrt{2}$

Langevin Dynamics의 목표는 충분히 긴 시간이 지난 후 샘플의 분포가

$$p_{\phi}(\mathbf{x}) = \frac{1}{Z} e^{-E_{\phi}(\mathbf{x})}$$

를 유지하도록 하는 것입니다. 따라서 **Stationary Distribution**에서는

$$\frac{\partial \rho(\mathbf{x}, t)}{\partial t} = 0, \quad \rho(\mathbf{x}, t) = p_{\phi}(\mathbf{x})$$

를 만족해야 합니다. 이를 Fokker-Planck 방정식에 대입하면

$$\left(\frac{\sigma^2}{2} - 1\right) \Delta_{\mathbf{x}} p_{\phi} = 0$$

을 얻습니다. 일반적으로 $\Delta_{\mathbf{x}} p_{\phi} \neq 0$ 이므로, 이 식이 항상 성립하기 위해서는

$$\frac{\sigma^2}{2} - 1 = 0$$

이어야 하며,

$$\sigma = \sqrt{2}$$

를 얻습니다. 즉, **Drift 항** ($-\nabla E_{\phi}$)과 **Diffusion 항** ($\sigma d\mathbf{w}$)이 정확히 균형을 이루는 경우가 $\sigma = \sqrt{2}$ 이며, 이때에만 원하는 확률분포

$$p_{\phi}(\mathbf{x}) = \frac{1}{Z} e^{-E_{\phi}(\mathbf{x})}$$

가 시간에 따라 변하지 않는 **Stationary Distribution**이 됩니다.

Langevin Sampling with Score Functions

⚙️ Langevin Dynamics 기반 샘플링

- Langevin Dynamics를 통한 샘플링 → 즉, Langevin SDE를 통한 샘플링 → 샘플 분포: Boltzmann 분포

EBM (Energy-Based Model)

$$p_{\phi}(\mathbf{x}) := \frac{\exp(-E_{\phi}(\mathbf{x}))}{Z_{\phi}}$$



Boltzmann 분포

$$p(\mathbf{x}) \propto \exp(-E(\mathbf{x}))$$

Ludwig Boltzmann (1844–1906)이 제안한 분포로, 열평형 상태에서 입자들이 각 에너지 상태에 분포하는 확률을 설명함

- Noise 덕분에 local minima를 탈출하면서, 결국 올바른 확률분포로 평가 받는 Boltzmann 분포로 수렴 가능
- EBM은 샘플을 높은 확률 영역으로 밀어주는 Force Field를 학습하는 것으로 볼 수 있음
- Langevin 샘플링: Partition Function Z_{ϕ} 계산 없이 EBM 분포 $p_{\phi}(\mathbf{x})$ 에서 샘플을 생성할 수 있는 실용적 방법

Langevin Sampling with Score Functions

⚙️ Continuous-Time Langevin Dynamics

– Langevin Stochastic Differential Equation (SDE)

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

$$\mathbf{x}(t) \xrightarrow{t \rightarrow \infty} p_{\phi}$$

– 다음 조건 하에서, Langevin SDE를 반복하여 업데이트하면, $\mathbf{x}(t)$ 가 결국 분포 $p_{\phi}(\mathbf{x})$ 로 수렴한다.

➤ 조건 1) Confining Energy (가두는 에너지)

- 에너지가 무한대로 가면 커짐 [예시: $E(\mathbf{x}) = \mathbf{x}^2$]
- "멀리 갈수록 에너지가 높아진다" = 공이 도망가지 못하게 벽이 있다.

$$E_{\phi}(\mathbf{x}) \rightarrow \infty \quad \text{as} \quad \|\mathbf{x}\| \rightarrow \infty$$

➤ 조건 2) Smooth

- 에너지 함수가 모든 구간에서 Gradient 계산 가능

➤ 조건 3)

- 확률분포 $p_{\phi}(\mathbf{x})$ 가 에너지의 지수함수 형태

$$p_{\phi}(\mathbf{x}) := \frac{\exp(-E_{\phi}(\mathbf{x}))}{Z_{\phi}}$$

Langevin Sampling with Score Functions

⚙️ Discrete-Time Langevin Dynamics

- 이산화(discretize) 필요성: Continuous SDE를 컴퓨터로 시뮬레이션하기 용이
- The discrete update rule comes from the Euler-Maruyama discretization of this continuous SDE.

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

이산화 적용 ↓

$$\mathbf{x}_{n+1} - \mathbf{x}_n = -\eta \nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

정리 ↓

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \eta \nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

Score Function 적용 ↓ $\nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})$

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

Langevin Sampling with Score Functions

⚙️ Discrete-Time Langevin Dynamics 예시 (1/4)

1. Discrete-Time Langevin Dynamics

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, I), \quad n = 0, 1, 2, \dots$$

여기서 핵심은 이미지 하단의 스코어-에너지 관계입니다:

$$\nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})$$

근거: 에너지 기반 모델(EBM)은 확률을 $p_{\phi}(\mathbf{x}) = \frac{e^{-E_{\phi}(\mathbf{x})}}{Z}$ 로 정의합니다. 양변에 $\log$ 를 취하면 $\log p_{\phi}(\mathbf{x}) = -E_{\phi}(\mathbf{x}) - \log Z$ 이고, 정규화상수 Z 는 $\mathbf{x}$ 에 무관하므로 미분하면 사라져 위 관계가 성립합니다.

Langevin Sampling with Score Functions

⚙️ Discrete-Time Langevin Dynamics 예시 (2/4)

2. 구체적인 예시: 1차원 가우시안을 EBM으로 표현

목표분포 (정규분포식)

일반적인 1차원 정규분포의 확률밀도함수(PDF)는 다음과 같습니다:

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

예시의 목표분포로 $\mu = 3$, $\sigma^2 = 1$ 을 대입하면:

$$p_\phi(x) = \mathcal{N}(x; 3, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x - 3)^2}{2}\right)$$

EBM(에너지 함수) 형태로 변환

이 분포를 에너지 기반 모델의 $p_\phi(x) \propto e^{-E_\phi(x)}$ 형태와 비교합니다. 위 PDF 지수부의 $-\frac{(x - 3)^2}{2}$ 가 $-E_\phi(x)$ 에 해당하므로:

$$E_\phi(x) = \frac{(x - 3)^2}{2}, \quad Z = \sqrt{2\pi} \text{ (정규화상수)}$$

Langevin Sampling with Score

⚙️ Discrete-Time Langevin Dynamics 예시 (3/4)

에너지의 기울기 (에너지 형태 갱신식에 들어가는 항):

$$\nabla_x E_\phi(x) = (x - 3)$$

스코어 (스코어-에너지 관계식 적용):

$$\nabla_x \log p_\phi(x) = -\nabla_x E_\phi(x) = -(x - 3)$$

두 형태를 각각 최종 갱신식에 넣으면 (당연히 결과가 같아야 함):

$$\underbrace{x_{n+1} = x_n - \eta(x_n - 3) + \sqrt{2\eta}\epsilon_n}_{\text{에너지 형태}} = \underbrace{x_n + \eta(-(x_n - 3)) + \sqrt{2\eta}\epsilon_n}_{\text{스코어 형태}}$$

$$dx(t) = -\nabla_x E_\phi(x(t))dt + \sqrt{2} dw(t)$$

이산화 적용 $\Downarrow$

$$\mathbf{x}_{n+1} - \mathbf{x}_n = -\eta \nabla_x E_\phi(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

정리 $\Downarrow$

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \eta \nabla_x E_\phi(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

Score Function 적용 $\Downarrow$ $\nabla_x \log p_\phi(\mathbf{x}) = -\nabla_x E_\phi(\mathbf{x})$

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_x \log p_\phi(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n, \quad n = 0, 1, 2, \dots,$$

Langevin Sampling with Score Functions

⚙️ Discrete-Time Langevin Dynamics 예시 (4/4)

3. 실제 숫자로 몇 스텝 돌려보기

설정: 스텝 크기 $\eta = 0.05$ 이므로 노이즈 계수 $\sqrt{2\eta} = \sqrt{0.1} \approx 0.3162$. 시작점 $x_0 = 0$ (일부러 평균 3에서 멀리 배치).

$$\text{갱신식: } x_{n+1} = x_n - 0.05 (x_n - 3) + 0.3162 \epsilon_n$$

Step 1 (예시 노이즈 $\epsilon_0 = 0.5$):

$$x_1 = 0 - 0.05 (0 - 3) + 0.3162 \cdot 0.5 = 0 + \underbrace{0.150}_{\text{drift } -\eta \nabla E} + \underbrace{0.158}_{\text{noise}} = 0.308$$

Step 2 ($\epsilon_1 = -0.3$):

$$x_2 = 0.308 - 0.05 (0.308 - 3) + 0.3162 \cdot (-0.3) = 0.308 + 0.135 - 0.095 = 0.348$$

Step 3 ($\epsilon_2 = 1.2$):

$$x_3 = 0.348 - 0.05 (0.348 - 3) + 0.3162 \cdot 1.2 = 0.348 + 0.133 + 0.379 = 0.860$$

값이 점점 평균 3 쪽으로 이동합니다.

동작 원리 (근거): drift 항 $-\eta \nabla_x E_\phi(x_n) = -0.05 (x_n - 3)$ 은 항상 에너지 E_ϕ 가 낮아지는 방향, 즉 확률 p_ϕ 가 높은 평균 3 쪽으로 끌어당깁니다. x_n 이 3에서 멀수록 이 힘이 커지고 가까워지면 약해집니다. 반면 $\sqrt{2\eta} \epsilon_n$ 은 매 스텝 무작위로 흔들어, 하나의 점으로 수렴하지 않고 분포 전체를 탐색하게 만듭니다. 충분한 스텝 후 x_n 은 평균 3, 분산 1 주위에서 진동하며 $\rightarrow \mathcal{N}(3, 1)$ 에서 뽑은 샘플처럼 분포합니다.

Langevin Sampling with Score Functions

⚙️ Inherent Challenges of Langevin Sampling

- Langevin 샘플링은 고차원 공간에서 매우 비효율적임
 - 거대한 에너지 기반 지형도를 설계하는 일은 매우 어려움
- Langevin 샘플링 성능은 스텝 크기 η , 노이즈 크기, 반복 횟수에 매우 민감함
 - 스텝 크기 η 가 작을 수록 샘플 성능이 높아짐
- 핵심 문제는 mixing time이 매우 느리다는 것
- 다중 모드 분포(Multi-mode Distribution)에서 확률이 높은 영역 간 이동이 어려움
- 차원이 증가할수록 수렴 속도가 급격히 저하됨
- 국소적 업데이트 방식으로 인해 분포의 다양성을 충분히 포착하지 못함
- 따라서, 보다 구조적이고 유도된 샘플링 방법의 필요성이 제기됨

From Energy-Based to Score-Based Generative Models

Training with Score Matching

Score Matching (with Neural Network)

핵심 통찰 (KEY INSIGHT)

랑주뱅 다이내믹스를 이용한 샘플링에는 정규화된 밀도가 아닌, 오직 **스코어 함수**만 필요합니다.

따라서 에너지 함수 $E_\phi(\mathbf{x}(t))$ 를 모델링하고 복잡한 미분을 계산하는 대신, 스코어 자체를 직접 학습하는 것이 더 효율적입니다.

스코어 기반 생성 모델 (Score-Based Models)

$$\mathbf{s}_\theta(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log p_{\text{data}}(\mathbf{x})$$

- ✓ 직접적인 벡터장 학습: 신경망 $\mathbf{s}_\theta(\mathbf{x})$ 가 데이터의 기울기 벡터장을 직접 출력합니다.
- ✓ 분배 함수 우회: 학습 과정에서 z 를 계산할 필요가 없어 EBM의 고질적인 병목 현상을 해결합니다.
- ✓ 점진적 노이즈 제거: 생성 과정은 노이즈를 데이터로 정제해 나가는 반복적인 과정으로 정의됩니다.

PARADIGM SHIFT: ENERGY → SCORE

[패러다임의 전환]

- 랑주뱅 다이내믹스를 이용한 샘플링에는 정규화된 밀도 함수($p_\phi(\mathbf{x})$)가 아니라, 오직 스코어 함수만 필요
- 굳이 에너지 함수를 모델링하고 복잡한 2차 미분까지 계산할 필요가 없음.
- 에너지 모델을 우회하고 스코어 자체를 직접 학습하는 스코어 기반 생성 모델로 전환
- 신경망이 데이터의 기울기 벡터장을 직접 출력하도록 학습시키는 것
- 이 에너지에서 스코어로의 전환이 바로 현대 생성 모델의 혁신을 이끌어낸 기반이 됨

Training with Score Matching

⚙️ Score Matching (with Neural Network)

- To approximate the score function $\mathbf{s}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{data}(\mathbf{x})$ from samples of p_{data} , we approximate it directly as "a vector field parameterized by a neural network $\mathbf{s}_{\phi}(\mathbf{x})$ "
- Score matching fits this vector field by minimizing MSE between the true and estimated scores

$$\mathcal{L}_{SM}(\phi) := \frac{1}{2} \mathbb{E}_{p_{data}(\mathbf{x})} \left\| \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p_{data}(\mathbf{x}) \right\|_2^2$$



$$\mathcal{L}_{SM}(\phi) := \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{data}} \left[\left\| \mathbf{s}_{\phi}(\mathbf{x}) - \mathbf{s}(\mathbf{x}) \right\|_2^2 \right]$$

- However, it is still infeasible since the true score $\mathbf{s}(\mathbf{x})$ is unknown




Figure 3.4: Illustration of Score Matching. The neural network score $\mathbf{s}_{\phi}(\mathbf{x})$ is trained to match the ground truth score $\mathbf{s}(\mathbf{x})$ using a MSE loss. Both are represented as vector fields.

Training with Score Matching

⚙️ Tractable Score Matching (with Neural Network)

- It depends only on the model $\mathbf{s}_\phi(\mathbf{x})$ and the data samples, without requiring access to the true score

$$\mathcal{L}_{\text{SM}}(\phi) := \frac{1}{2} \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} \left[\|\mathbf{s}_\phi(\mathbf{x}) - \mathbf{s}(\mathbf{x})\|_2^2 \right]$$

integration by parts

Proposition 3.2.1: Hyvärinen's Tractable Form of SM

We can express the following equation as:

$$\mathcal{L}_{\text{SM}}(\phi) = \tilde{\mathcal{L}}_{\text{SM}}(\phi) + C.$$

where

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_\phi(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_\phi(\mathbf{x})\|_2^2 \right], \quad (3.2.2)$$

and C is a constant that does not depend on ϕ . The minimizer $\mathbf{s}^*$ is obtained as: $\mathbf{s}^*(\cdot) = \nabla_{\mathbf{x}} \log p(\cdot)$.


- Using the equivalent objective in Equation (3.2.2), we train the score model $\mathbf{s}_\phi(\mathbf{x})$ solely from observed samples of p_{data} , eliminating the need for the true score function

Training with Score Matching

⚙️ Tractable Score Matching (with Neural Network)

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr} \left(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}) \right) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right]$$

- The norm term $\frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2$
 - It suppresses the score in regions where p_{data} is large, making them stationary
- The divergence term $\text{Tr} \left(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}) \right)$
 - It favors negative values, so these stationary points act as attractive sinks.



Training with Score Matching

⚙️ Jacobian, Hessian, Divergence

수식 1: $\nabla_x \mathbf{s}_\phi = \nabla_x^2 u$ (Hessian)

단계별 이해

Step 1: u 의 gradient (벡터)

$$\nabla_x u = \begin{pmatrix} \frac{\partial u}{\partial x_1} \\ \frac{\partial u}{\partial x_2} \\ \vdots \\ \frac{\partial u}{\partial x_D} \end{pmatrix} = \mathbf{s}_\phi$$

Step 2: 이 벡터를 다시 미분하면? (Jacobian)

$$\nabla_x \mathbf{s}_\phi = \nabla_x (\nabla_x u) = \begin{pmatrix} \frac{\partial^2 u}{\partial x_1 \partial x_1} & \frac{\partial^2 u}{\partial x_1 \partial x_2} & \cdots \\ \frac{\partial^2 u}{\partial x_2 \partial x_1} & \frac{\partial^2 u}{\partial x_2 \partial x_2} & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

설정

스칼라 함수 $u : \mathbb{R}^D \rightarrow \mathbb{R}$ 이 있고, score를 다음과 같이 정의:

$$\mathbf{s}_\phi = \nabla_x u$$

$$\mathbf{s}_\phi(\mathbf{x}) = \nabla_x \log p_{data}(\mathbf{x})$$

Step 3: 이것이 바로 Hessian!

$$\nabla_x^2 u = \text{Hessian of } u$$

요약

$$\underbrace{\nabla_x \mathbf{s}_\phi}_{\text{score의 Jacobian}} = \underbrace{\nabla_x (\nabla_x u)}_{\text{gradient의 gradient}} = \underbrace{\nabla_x^2 u}_{\text{Hessian}}$$

Training with Score Matching

⚙️ Jacobian, Hessian, Divergence

수식 2: $\nabla \cdot \mathbf{s}_\phi = \text{Tr}(\nabla_x^2 u)$

Divergence란?

벡터장의 **발산(divergence)**은 각 성분을 해당 좌표로 미분한 것의 합:

$$\nabla \cdot \mathbf{s}_\phi = \frac{\partial[\mathbf{s}_\phi]_1}{\partial x_1} + \frac{\partial[\mathbf{s}_\phi]_2}{\partial x_2} + \dots + \frac{\partial[\mathbf{s}_\phi]_D}{\partial x_D}$$

$\mathbf{s}_\phi = \nabla_x u$ 대입

$$[\mathbf{s}_\phi]_i = \frac{\partial u}{\partial x_i}$$

따라서:

$$\nabla \cdot \mathbf{s}_\phi = \sum_{i=1}^D \frac{\partial}{\partial x_i} \left(\frac{\partial u}{\partial x_i} \right) = \sum_{i=1}^D \frac{\partial^2 u}{\partial x_i^2}$$

- 벡터장 $\vec{F}$ 의 발산(divergence)은 한 점에서의 유출·유입 정도를 나타내는 스칼라 값
- 해당 점이 소스(source) 인지 싱크(sink) 인지를 측정함
- $\nabla \cdot \vec{F}$ (델 연산자와 벡터장의 내적)으로 계산됨

설정

스칼라 함수 $u : \mathbb{R}^D \rightarrow \mathbb{R}$ 이 있고, score를 다음과 같이 정의:

$$\mathbf{s}_\phi = \nabla_x u$$

Trace와의 연결

Hessian의 대각 성분:

$$\nabla_x^2 u = \begin{pmatrix} \boxed{\frac{\partial^2 u}{\partial x_1^2}} & \dots & \dots \\ \dots & \boxed{\frac{\partial^2 u}{\partial x_2^2}} & \dots \\ \dots & \dots & \boxed{\frac{\partial^2 u}{\partial x_D^2}} \end{pmatrix}$$

Trace = 대각 성분의 합:

$$\text{Tr}(\nabla_x^2 u) = \frac{\partial^2 u}{\partial x_1^2} + \frac{\partial^2 u}{\partial x_2^2} + \dots + \frac{\partial^2 u}{\partial x_D^2}$$

$$\nabla \cdot \mathbf{s}_\phi = \text{Tr}(\nabla_x^2 u)$$

Training with Score Matching

⚙️ Jacobian, Hessian, Divergence

2D 구체적 예시

$$u(x_1, x_2) = -\frac{1}{2}(x_1^2 + x_2^2) \text{ (2D 정규분포의 log-density)}$$

계산	결과
$\mathbf{s}_\phi = \nabla u$	$(-x_1, -x_2)^\top$
$\nabla_x \mathbf{s}_\phi$ (Jacobian)	$\begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$
$\nabla_x^2 u$ (Hessian)	$\begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \checkmark \text{ 같음!}$
$\nabla \cdot \mathbf{s}_\phi$	$-1 + (-1) = -2$
$\text{Tr}(\nabla_x^2 u)$	$-1 + (-1) = -2 \checkmark \text{ 같음!}$

설정

스칼라 함수 $u : \mathbb{R}^D \rightarrow \mathbb{R}$ 이 있고, score를 다음과 같이 정의:

$$\mathbf{s}_\phi = \nabla_x u$$

최종 요약

수식	의미
$\nabla_x \mathbf{s}_\phi = \nabla_x^2 u$	Score의 Jacobian = u 의 Hessian
$\nabla \cdot \mathbf{s}_\phi = \text{Tr}(\nabla_x^2 u)$	Score의 Divergence = Hessian의 Trace

Training with Score Matching

⚙️ Tractable Score Matching

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr} \left(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}) \right) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right]$$


– The norm term $\frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2$

역할: 고밀도 영역에서 score를 0으로 만들

기대값이 p_{data} 하에서 계산됨 $\Rightarrow$ 데이터가 많은 곳이 loss에 크게 기여

영역	p_{data}	Loss 기여	결과
고밀도 (데이터 많음)	높음	큼	$\mathbf{s}_{\phi} \rightarrow \mathbf{0}$ (정류점)
저밀도 (데이터 적음)	낮음	작음	덜 중요

직관: 확률의 peak(정상)에서는 gradient가 0이어야 함 $\rightarrow$ score도 0



Training with Score Matching

⚙️ Tractable Score Matching

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr} \left(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}) \right) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right]$$


– Divergence Term $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}))$

역할: 정류점이 **끌어당기는 점(sink)**이 되도록 함

$$\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}) = \nabla \cdot \mathbf{s}_{\phi} = \sum_{i=1}^D \frac{\partial [\mathbf{s}_{\phi}]_i}{\partial x_i}$$

Divergence	의미	벡터장 모양
양수	벡터들이 퍼져나감 (source)	$\leftarrow \cdot \rightarrow$
음수	벡터들이 모여듦 (sink)	$\rightarrow \cdot \leftarrow$

Loss가 음수 **divergence**를 선호 → 고밀도 영역이 sink가 됨



Training with Score Matching

⚙️ Tractable Score Matching

$$\tilde{\mathcal{L}}_{\text{SM}}(\phi) := \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \left[\text{Tr} \left(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}) \right) + \frac{1}{2} \|\mathbf{s}_{\phi}(\mathbf{x})\|_2^2 \right]$$

– Divergence Term $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x}))$

💡 Key Insight

- Let us define $\mathbf{s}_{\phi}(\mathbf{x}) = \nabla_{\mathbf{x}} u(\mathbf{x}) = \nabla_{\mathbf{x}} \log p(\mathbf{x})$ where $u: \mathbb{R}^D \rightarrow \mathbb{R}$
- At a stationary point $\mathbf{x}_{\star}$ where $\mathbf{s}_{\phi}(\mathbf{x}_{\star}) = \nabla_{\mathbf{x}} u(\mathbf{x}_{\star}) = \mathbf{0}$, a second order Taylor expansion gives

$$\begin{aligned} u(\mathbf{x}) &= u(\mathbf{x}_{\star}) + \nabla_{\mathbf{x}} u(\mathbf{x}_{\star})^{\top} (\mathbf{x} - \mathbf{x}_{\star}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_{\star})^{\top} \nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star}) (\mathbf{x} - \mathbf{x}_{\star}) + o(\|\mathbf{x} - \mathbf{x}_{\star}\|^2) \\ &= u(\mathbf{x}_{\star}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_{\star})^{\top} \nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star}) (\mathbf{x} - \mathbf{x}_{\star}) + o(\|\mathbf{x} - \mathbf{x}_{\star}\|^2) \end{aligned}$$

- Hessian $\nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star})$ is "Negative Definite"
 - $u(\mathbf{x}_{\star}) > u(\mathbf{x})$ [$u(\mathbf{x})$ 는 위로 볼록 (concave, $\cap$)]
 - local maximum 을 지남 → $\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\phi}(\mathbf{x})) < 0$
- Learned vector field has negative divergence and the stationary point is a sink

Hessian의 모든 eigenvalue가 음수:

$$\lambda_1 < 0, \quad \lambda_2 < 0, \quad \dots, \quad \lambda_D < 0$$

따라서:

$$\text{Tr}(\nabla_{\mathbf{x}}^2 u(\mathbf{x}_{\star})) = \lambda_1 + \lambda_2 + \dots + \lambda_D < 0$$

Training with Score Matching

⚙️ Sampling with Langevin Dynamics

- The trained score model $\mathbf{s}_{\phi^{\times}}(\mathbf{x})$ can replace the oracle score in Langevin dynamics for sampling
- Continuous-time Langevin SDE

$$d\mathbf{x}(t) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$



$$d\mathbf{x}(t) = \mathbf{s}_{\phi^{\times}}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

- Discrete-time Langevin Dynamics
 - The Euler–Maruyama discretization of the continuous-time Langevin SDE
 - $\nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}) = -\nabla_{\mathbf{x}} E_{\phi}(\mathbf{x})$, $\epsilon_n \sim \mathcal{N}(0, I)$, and for $n = 0, 1, 2, \dots$, initialized at $\mathbf{x}_0$

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \nabla_{\mathbf{x}} \log p_{\phi}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n$$



$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \mathbf{s}_{\phi^{\times}}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n,$$

Training with Score Matching

⚙️ Sampling with Langevin Dynamics

방법 1: Discrete Sampler (이산 샘플러)

$$\mathbf{x}_{n+1} = \mathbf{x}_n + \eta \mathbf{s}_{\phi^*}(\mathbf{x}_n) + \sqrt{2\eta} \epsilon_n$$

특징	설명
구현	단순한 for 루프
Step size	고정된 η 사용
장점	구현이 매우 쉬움
단점	η 가 크면 오차 발생

방법 2: SDE Solver (연속 SDE 시뮬레이션)

$$d\mathbf{x}(t) = \mathbf{s}_{\phi^*}(\mathbf{x}(t))dt + \sqrt{2} d\mathbf{w}(t)$$

특징	설명
구현	수치적 SDE solver 사용
Step size	적응적(adaptive)으로 조절 가능
장점	더 정확한 시뮬레이션
단점	구현이 더 복잡